

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ KATEDRA

**Rodiklių duomenų kaupimas, transformavimas ir
analizė, naudojant srautinį duomenų apdorojimą**

**Indicator Data Collection, Transformation and Analysis Using
Stream Processing**

Kursinis darbas

Atliko:	3 kurso 5 grupės studentas Vytautas Žilinas	(parašas)
Darbo vadovas:	lekt. Andrius Adamonis	(parašas)

Vilnius – 2018

TURINYS

IVADAS	3
1. RODIKLIŲ DUOMENYS	4
1.1. Apibrėžimas	4
1.2. Charakteristikos	4
2. DUOMENŲ APDOROJIMO TIPAI	6
2.1. Srautinis duomenų apdorojimas	6
2.2. Reliacinės duomenų bazės duomenų apdorojimas	7
2.3. Kiti duomenų apdorojimo tipai	8
2.3.1. Paketinis duomenų apdorojimas	8
2.3.2. Lambda architektūra	8
2.3.3. Kappa architektūra	8
3. SRAUTINIO APDOROJIMO ARCHITEKTŪROS	9
3.1. Pristatymo semantika	9
3.2. Uždelstumas	9
3.3. Pralaidumas	10
3.4. Abstrakcijos lygis	10
3.5. Apibendrinimas	11
4. TESTINIŲ DUOMENŲ GENERATORIUS	13
4.1. Apibūdinimas	13
4.2. Paskirtis ir panaudojimo būdas	13
5. SPRENDIMO NAUDOJANČIO RELIACINĘ DUOMENŲ BAZĘ PRALAIIDUMO TESTAS	14
5.1. Apibūdinimas	14
5.2. Testavimo rezultatai	14
6. SRAUTINIO DUOMENŲ APDOROJIMO SPRENDIMO PRALAIIDUMO TESTAS	15
6.1. Apibūdinimas	15
6.2. Rezultatas	15
7. EXPERIMENTO APIBENDRINIMAS	16
7.1. Rezultatai	16
7.2. Eksperimento išvados	16
REZULTATAI IR IŠVADOS	17
LITERATŪRA	18

Įvadas

Darbo tikslas: Eksperimento būdu išbandyti rodiklių duomenų kaupimo, transformavimo ir analizės uždavinių sprendinius, palyginant sprendimą, naudojanti reliacinę duomenų bazę, su sprendimu naudojančiu srautinį duomenų apdorojimą.

Užduotys:

1. Atlikti skirtingų srautinio duomenų apdorojimo sprendimo architektūrų analizę, ir pasirinkti vieną iš jų tyrimui.
2. Sukurti testinių duomenų generatorių.
3. Išmatuoti duoto reliacinės duomenų bazės sprendimo pralaidumą.
4. Realizuoti srautinio duomenų apdorojimo architektūros rodiklių duomenų kaupimo sprendimą.
5. Išmatuoti srautinio duomenų apdorojimo sprendimo pralaidumą ir palyginti testavimo rezultatus.

1. Rodiklių duomenys

1.1. Apibrėžimas

Rodiklių duomenys - tai didelių duomenų tipas, kurį galima transformuoti ir analizuoti ir kuris yra sugrupuotas pagal rodiklius, pavyzdžiui: bazinė mėnesio alga, mirusiųjų skaičius pagal mirties priežastis, krituliai per metus. Šie duomenys dažniausiai yra saugomi reliacinėse duomenų bazėse, kur užklausus vartotojui skaičiuojami apibendrinti rodikliai - sumos, vidurkiai ir kita statistika. Lietuvoje pagrindinis rodiklių duomenų bazės pavyzdys yra „Lietuvos statistikos departamento“ duomenų bazė, kurios duomenis galima pasiekti <https://osp.stat.gov.lt/statistiniu-rodikliu-analize#/> puslapyje, kuris leidžia ieškoti duomenis pagal vieną arba kelis rodiklius. Didesnis pavyzdys yra „DataBank“ <http://databank.worldbank.org> - pasaulinio lygio rodiklių duomenų bazių rinkinys, turintis 69 skirtingas duomenų bazines, pavyzdžiui - „World development indicators“, „Gender statistics“ ir kitus[Ban18].

1.2. Charakteristikos

Apibrėžime minėjau, kad rodiklių duomenis yra didelių duomenų tipas, todėl galime jiems pritaikyti didelių duomenų charakteristikas ir apsibrėžti, kurios iš jų mums sudaro daugiausiai problemų. Šie iššūkiai apibrėžiami Gartner's Doug Laney pristatytu 3V modeliu[Lan01], kuris vėliau buvo papildytas Bernard Marr iki 5V modelio[Mar14]:

- Tūris (angl. Volume). Apibrėžia generuojamų duomenų kiekius. Didelių duomenų atveju yra šnekama apie duomenų kiekius, kuriuos yra sudetinga arba neįmanoma saugoti ir analizuoti tradicinėmis duomenų bazių technologijomis. Rodiklių duomenų kiekiai dažniausiai nesudaro problemos saugojant, tačiau didelė problema yra rodiklių duomenų analizė, kadangi tuos pačius duomenis reikia apdoroti pagal neapribotą skaičių skirtingų rodiklių.
- Greitis (angl. Velocity). Apibrėžia greitį, kuriuo nauji duomenis yra generuojami. Rodiklių duomenų atveju, tai yra labai svarbu, kadangi nauji duomenis, kurie gali tikti skirtingiems rodikliams yra generuojami pastoviai.
- Įvairovė (angl. Variety). Apibrėžia duomenų tipus. Duomenys gali būti: strukturizuoti, nestrukturizuoti arba dalinai strukturizuoti[ZE⁺11]. Rodiklių duomenis dažniau yra strukturizuoti, todėl tai nėra aktualus iššūkis.
- Tikrumas (angl. Veracity). Apibrėžia duomenų tesingumą ir kokybę. Pavyzdžiui, jeigu analizuotume „Twitter“ socialinio tinklo žinučių turinį gautume daug gramatikos klaidų, naujadarų, slengo. Statistinio departamento atveju duomenys visada bus tvarkingi, kadangi tai dažniausiai yra duomenys surinkti iš dokumentų ir apklausų, o ne laisvo įvedimo.
- Vertė (angl. Value). Apibrėžia duomenų ekonominę vertę. Rodiklių duomenys yra labai vertingi įstaigoms, nes dažniausiai tos įstaigos užsiema tik rodiklių duomenų kaupimu ir analizė, iš techninės pusės ši charakteristika yra svarbi iš tos pusės, kad duomenų apdorojimo ir kaupimo sprendimai labai stipriai daro įtaką įstaigos, kaupiančios rodiklių duomenis, ekonomikai. Taip pat šių duomenys ir jų analizė turi būti pasiekiami be prastovos laiko.

Pagal apibrėžtas charakteristikas matome, kad pagrindiniai rodiklių duomenų iššūkiai yra tūris, greitis ir vertė. Todėl mūsų bandomas sprendimas turi galėti greitai susidoroti nebutinai dideliu kiekiu skirtingo pobūdžio duomenų ir turi sugebėti greitai atvaizduoti pokyčius atsiradus naujiems duomenims, taip pat turi būti įmanoma šį sprendimą paleisti į realią aplinką nepertraukiant įstaigos veiklą.

2. Duomenų apdorojimo tipai

2.1. Srautinis duomenų apdorojimas

Srautinis duomenų apdorojimas (angl. Stream processing) - yra programavimo paradigma ekvivalenti seniai aprašyti duomenų tekės programavimo (angl. dataflow programming) paradigmamui[Bea15]. Duomenų tekės programavimo paradigmos idėja, kad visa programa susidaro iš skirtingų modulių, kurie nepriklauso vienas nuo kito ir būtent tai leidžia sukonstruoti pralaidias skaičiuojančias programas. Viena iš pirmųjų duomenų tekės programavimo kompiliatorių yra BLODI - blokų diagramų kompiliatorius (angl. BLOck DIagram compiler), su kuriuo buvo kompiliuojamos BLODI programavimo kalba parašytos programos. Šia kalba parašytos programos atitinka inžinierinę elektros grandinės schemą, kur duomenis keliauja per komponentus kaip ir elektros grandinėje. Vienas iš šios programavimo kalbos privalumų buvo tai, kad ją galėjo išmokyti žmonės, kurie nebuvo programavimo ekspertai[KL61].

Kad apžvelgti modernias srautinio duomenų apdorojimo architektūras reikia apsibrėžti srautinio apdorojimo sistemų galimybes. 2005 metais Michael Stonebraker apibendrė 8 taisyklės realaus laiko srautinio duomenų apdorojimo architektūroms[SCZ05]:

- 1 taisyklė: Duomenys turi judėti. Kad būtų užtikrinta žemas uždelstumas sistema turi apdoroti duomenis nenaudojant duomenų saugojimo operacijas. Taip pat sistema turi ne pati užklausti duomenis, o gauti juos iš kito šaltinio automatiškai.
- 2 taisyklė: Duomenų transformacijos turi būti vykdomas SQL pobūdžio užklausomis. Žemo lygio srautinio apdorojimo sistemos reikalauja ilgesnio programavimo laiko ir brangesnio palaikymo. Tuo tarpu aukšto lygio sistema naudojanti SQL užklausas, kurias žino dauguma programuotojų ir naudojama daug skirtingų sistemų, leidžia efektyviau kurti srautinio apdorojimo sprendimus.
- 3 taisyklė: Architektūra turi susidoroti su duomenų netobulumais. Architektūra turi palaikyti galimybę nutraukti individualius skaičiavimus, tam kad neatsirastų blokuojančių operacijų. Taip pat ši architektūra turi sugebėti susidoroti su veluojančiomis žinutėmis, pratesiant laiko tarpą per kurį tą žinutė turi ateiti.
- 4 taisyklė: Architektūra turi generuoti nuspėjamus rezultatus. Kiekvieną kartą apdorojant tuos pačius duomenis rezultatai turi būti gaunami tokie patys.
- 5 taisyklė: Architektūra turi gebėti apdoroti išsaugotus duomenis ir realiu laiku gaunamus duomenis. Sistema parašyta su tokia architektūra turi galėti apdoroti jau esančius duomenis taip pat kaip ir naujai ateinančius. Toks reikalavimas atsirado, nes reikėjo galimybės nepastebimai perjungti apdorojimą iš istorinių duomenų į gyvus realiu laiku ateinančius duomenis automatiškai.
- 6 taisyklė: Architektūra turi užtikrinti duomenų saugumą ir apdorojimo prieinamumą. Kadangi sistema turi apdoroti didelius kiekius duomenų, architektūra, klaidos atveju, turi sugebėti persijungti į atsarginę sistemą ir testuoti darbą toliau. Taip pat tokios klaidos atveju atsarginė sistema turi būti apdorojusi visus duomenis ir sugebėti iš karto priimti naujus duomenis, o ne apdoroti duomenis iš pradžių.

7 taisyklė: Architektūra turi užtikrinti sugebėjimą paskirstyti sistemos darbus automatiškai. Srautinio apdorojimo sistemos turi palaikyti kelių procesoriaus gijų operacijas. Taip pat sistema turi galėti veikti ant kelių kompiuterių vienu metu ir prireikus paskirstyti resursus pagal galimybes.

8 taisyklė: Architektūra turi apdoroti ir atsakyti momentaliai. Anksčiau minėtos taisyklės nėra svarbius, jeigu sistema nesugeba greitai susidoroti su dideliu kiekiu naujų duomenų. Kad tai sistema pasiektu turi būti naudojamas ne tik tesingas ir greitas srautinio apdorojimo sprendimas, bet ir gerai optimizuota sistema.

Šie reikalavimai yra sukurti tik teoriškai ir egzistuoja labai nedaug srautinio apdorojimo architektūrų atitinkančių visas šias taisykles. Tam kad išsirinkti tinkamą architektūrą sprendžiamam uždaviniui, konkrečios srautinio apdorojimo architektūros yra apžvelgiamos ir lyginamos 3 skyriuje.

2.2. Reliacinės duomenų bazės duomenų apdorojimas

Reliacinės duomenų bazių valdymo sistemos (angl. Relational database management systems) - tai duomenų valdymo sistema paremta reliaciniu modeliu pirmą kartą aprašytu 1969 metais[Cod69]. Pagal <https://db-engines.com/en/ranking> 2018 metų birželio mėnesio rodiklius šiuo metu pagal populiarumą tarp reliacinių ir NoSQL duomenų bazių sistemų pirmos 5 vietos iš 343 yra paskirstytos atitinkamai:

1. Oracle (Reliacinė DBVS) - 1311.25
2. MySQL (Reliacinė DBVS) - 1233.69
3. Microsoft SQL Server (Reliacinė DBVS) - 1087.73
4. PostgreSQL (Reliacinė DBVS) - 410.67
5. MongoDB (NoSQL DBVS paremta dokumentų saugyklos modeliu) - 343.79

Šie rezultatai yra apskaičiuojami pagal „DB-engines“ algoritmą, kuris atsižvelgia į sistemų paminėjimus svetainėse, paieškos dažnį paieškos varikliuose, techninių diskusijų kiekį žinomose su informacinėmis technologijomis susijusiose svetainėse, profesionalių tinklų profiliuose, populiarumą socialiniuose tinkluose[DBE18]. Aiškiai matome, kad reliacinės duomenų bazių valdymo sistemos stipriai lenkia, bet kokias kitas saugyklas. Būtent toks populiarumas ir lemia, kad jos yra dažnai naudojamos ir duomenų apdorojimui. Kadangi reliacinė duomenų bazė jau egzistuoja, reiškia įmonei nereikia leisti papildomų lėšų: išanalizuoti kitokios sistemos tinkamumą užduočiai, sukurti sprendimą, palaikyti naują sistemą, pasisiamdyti naują žmogų mokanti dirbti su šia sistema arba apmokyti esamą.

Reliacinių duomenų bazių duomenų apdorojimo būdas yra išsaugotos procedūros(angl. stored procedures), kurios aprašomos SQL kalba ir gali apdoroti duomenis tiesiai iš duomenų bazės naudojant reliacinę matematiką. Tačiau jeigu pažiuresime į išsaugota procedūrą, kaip duomenų apdorojimo architektūrą pagal 2.1 skyriuje apibrėžtas 8 taisykles, pastebėsime, kad ji neatitinka: 1-os taisyklės: Duomenys turi judėti. Išsaugota procedūra yra leidžiama tik vartotojui užklausus, todėl šis reikalavimas yra neišpildytas, ir 7-os taisyklės: Architektūra turi užtikrinti sugebėjimą paskirstyti sistemos darbus automatiškai. Didžioji dalis reliacinių duomenų bazių nepalaiko horizontalų

plečiamumą[Cat11; Ram16] ir todėl vieną sistemą gali apdoroti tik tas, kas ją esančius duomenis. Svarbiausiai, išsaugota procedūra negali apdoroti greitai naujų duomenų įėjimo duomenų bazėje, jei yra didelis kiekis duomenų, kuriuos reikia apdoroti, nes procedūra apdoroja ne tik naujus bet visus duomenis, tai pažeisdama 8-tą duomenų apdorojimo taisyklę, ir ko pasekoje reliacinis sprendimas analitiškai yra mažiau tinkamas rodiklių duomenų problemai.

2.3. Kiti duomenų apdorojimo tipai

2.3.1. Paketinis duomenų apdorojimas

Paketinis duomenų apdorojimas (angl. Batch processing) - didelių duomenų apdorojimo tipas, kai surinktas didelis duomenų kiekis nėra apdorojamas iš karto, o sukaupiamas ir vėliau apdorojamas visas iš karto. Mūsų reliacinės duomenų bazės apdorojimas naudoja primitivią paketinio duomenų apdorojimo versiją. Daug geriau yra žinomas kita paketinio duomenų apdorojimo architektūra - „Apache Hadoop“. Ši architektūra naudoja „Google“ sukurtą „Map-Reduce“ konceptą[DG08], kuris didelių duomenų kiekį suskaido į mažus rinkinius ir daro apdorojimą paraleliai ant visų rinkinių.[RHK⁺15] Ši architektūra mums netinka, nes mes norime rezultatą gauti tik įdėję naujų duomenų.

2.3.2. Lambda architektūra

Lambda architektūra - didelių duomenų apdorojimo architektūra naudojanti srautinio ir paketinio apdorojimo architektūrą. Su šia architektūra bandoma subalansuoti uždelstumą, pralaidumą ir klaidų toleranciją, naudojant paketinį apdorojimą tikslams ir išsamiesiems duomenų pakentams ir tuo pačiu metu naudoti srautinį apdorojimą greitai analizei[HKV14]. Tačiau ši architektūra turi vieną trūkumą - norint naudoti šią architektūrą reikia palaikyti dvi skirtingas architektūras, kad kodas būtų atnaujinamas abiejose architektūrose vienu metu[Kre14]. Vienas pavyzdys tokios architektūros būtų - Kafka žinučių sistema siunčianti duomenis į „Apache Storm“, kur duomenis apdorojami srautiškai, ir „Apache Hadoop“, kur duomenis apdorojami paketiškai, ir rezultatus saugant skirtingose duomenų bazės lentelėse.

2.3.3. Kappa architektūra

Kappa architektūra - tai supaprastinta lambda architektūra, kuri vietoj paketinio apdorojimo naudoja papildomą srautinio apdorojimo sistemą. Pavyzdžiui yra vienas srautinio apdorojimo darbas, kuris veikia visą laiką ir atvaizduoja duomenis gyvai, ir yra kitas darbas, kuris paleidžiamas kas kažkiek laiko, kuris susirenka per visą tą laiką susikaupusius duomenis ir praleidžia per save srautu. Kadangi kodai yra vienodi, todėl nebeatsiranda anksčiau minėtų iššūkių su skirtingų sistemų palaikymu[Kre14; Pat14].

3. Srautinio apdorojimo architektūros

Šiame skyriuje palyginsime tris atviro kodo srautinio apdorojimo architektūras „Apache Storm“, „Apache Spark“ ir „Apache Flink“ pagal:

- Pristatymo semantika (angl. delivery semantics) - apibrezia pagal kokį modelį bus pristatyti duomenis. Egzistuoja trys semantikos[Kah18]:
 - Bent vieną kartą (angl. At-least-once) užtikrina, kad duomenis bus apdoroti bent kartą, bet gali atsirasti duplikatų.
 - Ne daugiau vieno karto (angl. At-most-once) užtikrina, kad duomenis bus apdoroti daugiausiai tik vieną kartą, bet gali atsirasti praradimų.
 - Tiksliai vieną kartą (angl. Exactly-once) užtikrina, kad duomenis bus apdoroti tik vieną kartą net ir atsiradus klaidoms.
- Uždelstumas (angl. Latency) - apibrezia kiek laiko užtruks įvykdyti kažkokį veiksmą arba gauti rezultatą.
- Pralaidumas (angl. Throughput) - apibrezia kiek pavyks įvykdyti operacijų per tam tikrą laiko tarpą.
- Abstrakcijos lygis (angl. Abstraction) - apibrezia kokio lygio programavimo sąsają pateikia architektūra.

3.1. Pristatymo semantika

„Apache Spark“ ir „Apache Storm“ architektūrų pristatymo semantika yra tiksliai vieną kartą (angl. Exactly-once), tai reiškia, kad visi duomenys bus apdoroti tik vieną kartą. Tačiau tam, kad užtikrinti šią semantiką architektūra sunaudoja daug resursų, nes reikia užtikrinti, kad operacija bus vykdoma būtent vieną kartą kiekvieniame srautinio apdorojimo žingsnyje: duomenų gavime, kas stipriai priklauso nuo duomenų šaltinio, duomenų transformacijos, kuri turi užtikrinti pati srautinio apdorojimo architektūra ir duomenų saugojime, kas turi būti užtikrinta architektūros ir naudojamų saugyklos[ZHA17].

„Apache Storm“ pristatymo semantika yra bent viena kartą (angl. at-least-once), kas reiškia, kad per šią architektūrą leidžiami duomenys visada pasieks pabaigą, tačiau kartais gali dubliuotis[DAM16]. Jeigu sprendimas reikalauja tiksliai vieno karto apdorojimo, tada mes turime rinktis arba vieną iš aukščiau minėtų architektūrų arba „Apache Storm Trident“ - ant „Apache storm“ architektūros pastatyta aukšto abstrakcijos lygio architektūra galinti užtikrinti tiksliai vieno karto apdorojimą. Tačiau jei uždavynis to nereikalauja, greičio, ypač uždelstumo, atveju daug geriau pasirinkti pigesnę pristatymo semantiką[ZHA17].

3.2. Uždelstumas

Uždelstumas, srautinio apdorojimo architektūroms yra matuojamas milisekundėmis, kas parodo kaip greitai architektūra įvykdo vieną operaciją. Pagal Martin Andreoni Lopez darytus bandymus su šiomis architektūromis galime matyti, kad būtent „Apache Storm“ turi mažiausią uždelstumą, parinkus teisingai paraleliškumą ši architektūra su užduotimi susidorojo net iki 15 kartų

greičiau. Antroje vietoje liko „Apache Flink”, o po jos „Apache Spark”[LLD16]. Tačiau dažniausiai kai architektura turi labai žemą uždelstumą, tai ji turės taip pat ir žemą pralaidumą, kas nėra gerai, kai norima apdoroti daug duomenų iš karto.

3.3. Pralaidumas

Pralaidumas apibrezia kokį kiekį procesų sistema gali įvykdyti per tam tikrą laiko tarpą. 2016 metais Sanket Chintapalli su kolegomis išmatavo „Apache Storm”, „Apache Spark” ir „Apache Flink” architektūrų pralaidumą ir uždelstumą ir palygino rezultatus. Kaip ir anksčiau manyta, „Apache Spark” turėjo aukščiausią pralaidumą iš visų, kadangi jis vienintelis iš trijų duomenis apdoroja mikro-paketais. Antroje vietoje liko „Apache Flink”, kuris yra subalansuotas uždelstumo, pralaidumo atveju ir paskutinis liko „Apache Storm”, kuris turi labai žemą uždelstumą, todėl nukečia pralaidumas[CDE⁺16].

3.4. Abstrakcijos lygis

Pats populiariausias srautinio apdorojimo architektūrų programos pavyzdys yra žodžių skaičiuoklė, kurios tikslas suskaičiuoti kiek kartu pasikartojo tas pats žodis, per visą programos veikimo laiką. Todėl abstrakcijos lygį geriausia palyginti šios programos kodo pavyzdžiais[Zap16]:

```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 5);
builder.setBolt("split", new Split(), 8).shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 12).fieldsGrouping("split", new Fields("word"));
...
Map<String, Integer> counts = new HashMap<String, Integer>();

public void execute(Tuple tuple, BasicOutputCollector collector) {
    String word = tuple.getString(0);
    Integer count = counts.containsKey(word) ? counts.get(word) + 1 : 1;
    counts.put(word, count);
    collector.emit(new Values(word, count));
}
```

1 pav. „Apache Storm” žodžių skaičiavimo programos kodo pavyzdys

„Apache Storm” parašytos programos yra žemo lygio abstrakcijos. 1 pavyzdyje matome labai sumažintą programos pavyzdį. Kadangi tai yra žemo lygio programa mes turime apsirašyti visas srauto apdorojimo stadijas pažingsniui, tai yra: setSpouts(..), kur nustatoma duomenų įeiga ir koks bus paralelizmas, setBolt(..), kur nustatomi apdorojimo moduliai, kokius duomenis gaus iš prieš tai buvusio modulio ir paralelizmas. Žemiau, execute() metodas aprašo, kaip gali atrodyti apdorojimo modulis, kuris suskaičiuoja kiek skirtingų žodžių pro jį praėjo. Šios architektūros programų kūrimo laikas užtruks ilgiau negu kitoms architektūroms su aukštu abstrakcijos lygiu, tačiau žemas abstrakcijos leidžia rašyti daug greičiau veikiančias programas, kadangi programuotojas turi beveik pilną kontrolę.

„Apache Spark” parašytos programos yra aukšto lygio abstrakcijos. 2 pavyzdyje matome realu beveik išbaigtą programos pavyzdį. Programa aprašoma funkciškai, todėl kodo rašymas trunka

```

SparkSession spark = SparkSession
    .builder()
    .appName("WordCount")
    .getOrCreate();

JavaRDD<String> lines = spark.read().textFile(...).javaRDD();
JavaRDD<String> words = lines.flatMap(s -> Arrays.asList(SPACe.split(s)).iterator());
JavaPairRDD<String, Integer> ones = words.mapToPair(s -> new Tuple2<>(s, 1));
JavaPairRDD<String, Integer> counts = ones.reduceByKey((i1, i2) -> i1 + i2);
List<Tuple2<String, Integer>> output = counts.collect();
for (Tuple2<?,?> tuple : output) {
    System.out.println(tuple._1() + ": " + tuple._2());
}
spark.stop();

```

2 pav. „Apache Spark” žodžių skaičiavimo programos kodo pavyzdys

daug trumpiau ir tokį kodą daug patogiau skaityti. Tačiau prarandama galimybė optimizuoti ir paralelizmo klausimas paliekamas architektūrai, taip pat „Apache Spark” yra ne pilnai srautinio, o mikro-paketinė (angl. micro-batching) architektūra, todėl vartotojas turi apsirašyti kokio dydžio paketais bus renkami duomenys[SS15].

```

final StreamExecutionEnvironment env = StreamExecutionEnvironment.getExecutionEnvironment();

env.getConfig().setGlobalJobParameters(params);
DataStream<String> text = env.fromElements(...);
DataStream<Tuple2<String, Integer>> counts =
    | text.flatMap(new Tokenizer())
    | | .keyBy(0).sum(1);
counts.print();
env.execute("Streaming WordCount");

```

3 pav. „Apache Flink” žodžių skaičiavimo programos kodo pavyzdys

„Apache Flink” parašytos programos yra aukšto lygio abstrakcijos. 3 pavyzdyje matome pilnai veikiančios programos pavyzdį. „Apache Flink” architektūra pati užsiema resursų distribucija, todėl programuotojui lieka tik parašyti veikianti kodą, o sistema pati susitvarkys su paralelizmu. Tačiau tai reiškia, kad su šia architektūra parašytos programos nepavyks optimizuoti taip pat gerai kaip žemo lygio abstrakcijos architektūros.

3.5. Apibendrinimas

Iš šių trijų text architektūrų reikia pasirinkti vieną, kuri labiausiai tiks rodiklių duomenų apdorojimui. Ši architektūra turi sugebėti greitai apdoroti duomenis, prioretizuojant greiti virš tikslumo, kadangi vienas iš pagrindinių naudotojų yra statistikų renkančios įstaigos, kurios gali sau leisti tam tikrą paklaidą, ir programuotojas turi galėti aprašyti daug skirtingų sprendimų skirtingiems rodikliams.

1 lentelė. Srautinių architektūrų palyginimas

Charakteristika	„Apache Storm”	„Apache Spark”	„Apache Flink”
Pristatymo semantika	Bent vieną kartą	Tiksliai vieną kartą	Tiksliai vieną kartą
Uždelstumas	Žemas	Aukštas	Vidutinis
Pralaidumas	Žemas	Aukštas	Vidutinis
Abstrakcijos lygis	Žemas	Aukštas	Aukštas

Kaip matome iš atliktos analizės 1 lentelėje ir apsibrėžtų reikalavimų, mums labiausiai tinkanti srautinio apdorojimo architektūra yra „Apache Storm”. Nors jos pralaidumas yra žemas, mums daug aktualiau yra greitis, taip pat žemas abstrakcijos lygis leis daug geriau optimizuoti sprendimą su šia architektūra. Su ją kursime sprendimą, kurį lyginsime su reliacinės duomenų bazės sprendimu.

4. Testinių duomenų generatorius

4.1. Apibūdinimas

Papasakoti čia apie Kafka

4.2. Paskirtis ir panaudojimo būdas

Papasakoti čia apie throtlinimo testavimą

5. Sprendimo naudojančio relaicinę duomenų bazę pralaidumo testas

5.1. Apibūdinimas

Kaip paruošiu sistema ir kodėl python turėtų būti pakankamai greitas sprendimas, kad ne-trukdytų rezultatams

5.2. Testavimo rezultatai

Oh shit its slow.

6. Srautinio duomenų apdorojimo sprendimo pralaidumo testas

6.1. Apibūdinimas

Dar čia parašysiu kokius išbandžiau variantus architektūros. Kaip testuosiu, su visais spoutais ir boltais ir t.t.

6.2. Rezultatas

Koks pralaidumas buvo, kaip sunku buvo paruošti sistemą, kiti rodikliai, kur stabdė.

7. Experimento apibendrinimas

7.1. Rezultatai

Palyginsiu srautinės ir reliacinės sprendimų pralaidumus.

7.2. Eksperimento išvados

Ką mes iš tu testu galime pasakyti.

Rezultatai ir išvados

Darbo rezultatai:

- Sukurtas testinių duomenų generatorius, kurio pagalba buvo vykdomas pralaidumo testavimas.
- Sukurtas sprendimas su pasirinkta srautinio apdorojimo architektūra.
- Atlikti pralaidumo testai sukurtam srautinio apdorojimo sprendimui, apibendrinti sprendimų pralaidumo testų rezultatai.

Darbo išvados:

-
-

Literatūra

- [Ban18] The World Bank. List of databank databases. <http://databank.worldbank.org/data/databases/>, 2018.
- [Bea15] Jonathan Beard. A short intro to stream processing. <http://www.jonathanbeard.io/blog/2015/09/19/streaming-and-dataflow.html>, 2015-09.
- [Cat11] Rick Cattell. Scalable sql and nosql data stores:12–27, 2011. URL: <http://doi.acm.org/10.1145/1978915.1978919>.
- [CDE⁺16] Sanket Chintapalli, Derek Dagit, Bobby Evans, Reza Farivar ir k.t. Benchmarking streaming computation engines: storm, flink and spark streaming. *Parallel and Distributed Processing Symposium Workshops, 2016 IEEE International*, p. 1789–1792. IEEE, 2016.
- [Cod69] Edgar F Codd. Derivability, redundancy, and consistency of relations stored in large data banks. Tech. atask., IBM Research Report, 1969.
- [DAM16] PRITHIVIRAJ DAMODARAN. “exactly-once” with a kafka-storm integration. <http://bytecontinnum.com/2016/06/exactly-kafka-storm-integration/>, 2016.
- [DBE18] DB-Engines. Method of calculating the scores of the db-engines ranking. https://db-engines.com/en/ranking_definition, 2018.
- [DG08] Jeffrey Dean ir Sanjay Ghemawat. Mapreduce: simplified data processing on large clusters. *Communications of the ACM*, 51(1):107–113, 2008.
- [HKV14] Zirije Hasani, Margita Kon-Popovska ir Goran Velinov. Lambda architecture for real time big data analytic. *ICT Innovations*, 2014.
- [Kah18] Ensar Basri Kahveci. Processing guarantees in hazelcast jet. <https://blog.hazelcast.com/processing-guarantees-hazelcast-jet/>, 2018.
- [KLK61] John L Kelly Jr, Carol Lochbaum ir Victor A Vyssotsky. A block diagram compiler. *Bell System Technical Journal*, 40(3):669–676, 1961.
- [Kre14] Jay Kreps. Questioning the lambda architecture. *Online article*, July, 2014.
- [Lan01] Doug Laney. 3d data management: controlling data volume, velocity and variety. *META Group Research Note*, 6(70), 2001.
- [LLD16] Martin Andreoni Lopez, Antonio Gonzalez Pastana Lobato ir Otto Carlos Muniz Bandeira Duarte. A performance comparison of open-source stream processing platforms. *2016 IEEE Global Communications Conference (GLOBECOM)*:1–6, 2016.
- [Mar14] Bernard Marr. Big data: the 5 vs everyone must know. *LinkedIn Pulse*, 6, 2014.
- [Pat14] Milinda Pathirage. What is kappa architecture. <http://milinda.pathirage.org/kappa-architecture.com/>, 2014.

- [Ram16] Jokūbas Ramanauskas. Išmaniųjų skaitiklių duomenų kaupimas, transformavimas ir analizė, naudojant newsql duomenų bazę, 2016.
- [RHK⁺15] Shyam R, Barathi Ganesh Hullathy Balakrishnan, Sachin Kumar S, Prabakaran Poor-nachandran ir Soman Kp. Apache spark a big data analytics platform for smart grid. 21:171–178, 2015-12.
- [SÇZ05] Michael Stonebraker, Uğur Çetintemel ir Stan Zdonik. The 8 requirements of real-time stream processing. *ACM Sigmod Record*, 34(4):42–47, 2005.
- [SS15] Abdul Ghaffar Shoro ir Tariq Rahim Soomro. Big data analysis: apache spark perspective. *Global Journal of Computer Science and Technology*, 2015.
- [Zap16] Petr Zapletal. Comparison of apache stream processing frameworks: part. <https://www.cakesolutions.net/teamblogs/comparison-of-apache-stream-processing-frameworks-part-1>, 2016.
- [ZE⁺11] Paul Zikopoulos, Chris Eaton ir k.t. *Understanding big data: Analytics for enterprise class hadoop and streaming data*. McGraw-Hill Osborne Media, 2011.
- [ZHA17] Ji ZHANG. How to achieve exactly-once semantics in spark streaming. <http://shzhangji.com/blog/2017/07/31/how-to-achieve-exactly-once-semantics-in-spark-streaming/>, 2017.